

最优化理论与技术



主讲：李古月

东南大学网络空间安全学院

E-mail: guyuelee@seu.edu.cn

办公地点：中国无线谷6307室

基础知识

- 矩阵的迹

$$\text{Tr}(A) = \sum_{i=1}^m a_{ii}$$

$$(A, B) \equiv \text{tr}(B^T A) = \text{tr}(A^T B) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ij}$$

- 矩阵的秩： 线性无关的横行（列向量）的个数

$$\text{rank}(AB) \leq \min(\text{rank } A, \text{rank } B)$$

$$\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$$

- 矩阵的行列式

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

- 半正定矩阵

基础知识

■ 例子:

$$x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$$

$$1\text{-范数} \quad \|x\|_1 = \sum_{i=1}^n |x_i|;$$

$$2\text{-范数} \quad \|x\|_2 = (x^T x)^{1/2} = \left(\sum_{i=1}^n x_i^2 \right)^{1/2};$$

$$\infty\text{-范数} \quad \|x\|_\infty = \max_i |x_i|;$$

$$p\text{-范数} \quad \|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, 1 \leq p < +\infty;$$

柯西-施瓦茨不等式

$$|\mathbf{x}^T \mathbf{y}| \leq \|\mathbf{x}\| \|\mathbf{y}\|$$

范数的等价性: $\mathbb{R}^n$ 上的任一范数 $\|x\|$ 都是 x 的连续函数, 并且任意两种范数 $N_1(x)$ 和 $N_2(x)$ 是等价的, 即存在常数 c_1, c_2 , 使得 $\forall x \in \mathbb{R}^n$, 有 $c_1 N_1(x) \leq N_2(x) \leq c_2 N_1(x)$

基础知识

定义 设 $A \in \mathbb{R}^{m \times n}$, 诱导的矩阵范数定义为

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$$

例子: 设 $A \in \mathbb{R}^{n \times n}$, 常用诱导的矩阵范数:

1-范数 $\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}|;$


2-范数 (谱范数) $\|A\|_2 = (\lambda_{\max}(A^T A))^{1/2},$

其中 $\lambda_{\max}(A)$ 表示矩阵 A 的最大特征值。

∞ -范数 $\|A\|_{\infty} = \max_i \sum_{j=1}^n |a_{ij}|;$

Frobenius-范数 $\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = (\text{tr}(A^T A))^{1/2},$ 其中 $\text{tr}(A)$ 表示 A 的迹 4

凸优化理论与算法



凸集

凸集

凸集、仿射集合

保凸运算

三种组合：仿射组合、凸组合、凸锥组合

三种集合：仿射集、凸集、凸锥集

三种包：仿射包、凸包、凸锥包

保凸运算

设 S_1 和 S_2 为 R^n 中两个凸集, β 是实数,则

1. $\beta S_1 = \{\beta x | x \in S_1\}$ 为凸集 2. $S_1 + \beta = \{x + \beta | x \in S_1\}$ 为凸集

3. $S_1 \cap S_2$ 为凸集

4. $S_1 + S_2 = \{x^{(1)} + x^{(2)} | x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集

5. $S_1 - S_2 = \{x^{(1)} - x^{(2)} | x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集

仿射函数 $f : R^n \rightarrow R^m$ 是仿射的,

当 $f(x) = Ax + b, A \in R^{m \times n}, b \in R^m$

若 $S \in R^n$ 为凸集, $f : R^n \rightarrow R^m$ 仿射, 则

$f(S) = \{f(x) | x \in S\}$ 为凸

例:

1. 证明集合 $C = \{x | \|x - x_c\|_\infty \leq r\}$ 是凸集, 其中 $x, x_c \in R^n, r \in R_{++}$. 集合 C 是仿射集吗? 是凸锥吗? (10 分)。

判断 $\{(x_1, x_2) | x_2 \geq 2|x_1|\}$ 是不是凸集, 并给出理由。(6 分)

凸函数

凸函数

4种判别方法

保凸运算

$$f(\lambda \mathbf{x}_1 + (1-\lambda)\mathbf{x}_2) \leq \lambda f(\mathbf{x}_1) + (1-\lambda)f(\mathbf{x}_2)$$

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*)$$

每一点的Hessian矩阵 $\mathbf{H}(\mathbf{x}) \succeq \mathbf{0}$

切西瓜定理: $g(t) = f(\mathbf{x} + t\mathbf{v})$

凸函数

函数的保凸运算

- 非负加权和 $f = w_1 f_1 + \cdots + w_m f_m,$
- 仿射映射 $g(x) = f(Ax + b),$
- 两个函数的极大值函数 $f(x) = \max\{f_1(x), f_2(x)\},$
- 复合函数 $f(x) = h(g(x))$
$$f'(x) = h'(g(x))g'(x)$$
$$f''(x) = h''(g(x))g'(x)^2 + h'(g(x))g''(x)$$

例:

1. 判别下列函数是否为凸函数, 写出过程 (10 分)

1) $f(x) = e^{-x} + \frac{1}{x}, x \in R_{++}$ (5 分)

2) $f(x_1, x_2) = x_1^2 + x_1x_2, x_1, x_2 \in R$ (5 分)


判断集合 $\{x | [\log_2(1+\alpha x) - \log_2(1+\beta x)]^+ > C, x \geq 0, C > 0\}$ 是否

是凸集, 并给出理由。其中 $[a]^+ = \max\{a, 0\}$, α, β, C 均为常数。

(6 分)

凸函数与凸集的关系

凸函数 f 的水平集 $L(f, \alpha) = \{x | x \in S, f(x) \leq \alpha\}, \alpha \in \mathbb{R}$
和上镜图 $\text{epi}(f) = \{(x, y) | x \in S, y \in \mathbb{R}, y \geq f(x)\}$
都是凸集



设 S 为 $\mathbb{R}^n$ 中的非空凸集,则 $f(x)$ 是凸的当且仅当上镜图
 $\text{epi } f = \{(x, y) | x \in S, y \in \mathbb{R}, y \geq f(x)\}$ 是凸集

凸优化问题

凸优化问题

标准形式

等价变换

典型问题

线性规划

(二次约束) 二次规划

半正定规划

凸优化问题

■ 标准形式

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & a_i^T x = b_i, \quad i = 1, \dots, p,\end{array}$$

■ 等价变换

- 变量替换
- 引出/消除等式约束
- 引入松弛变量
- 目标函数放到约束条件
- 先优化某些变量

典型问题

- 线性规划

$$\begin{array}{ll}\text{minimize}_{\mathbf{x}} & \mathbf{c}^T \mathbf{x} + d \\ \text{subject to} & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b}\end{array}$$

- 二次规划

$$\begin{array}{ll}\text{minimize}_{\mathbf{x}} & \frac{1}{2} \mathbf{x}^T \mathbf{P}\mathbf{x} + \mathbf{q}^T \mathbf{x} + r \\ \text{subject to} & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b}\end{array}$$

典型问题

- 二次约束二次规划

$$\begin{aligned} & \underset{\mathbf{x}}{\text{minimize}} && \frac{1}{2} \mathbf{x}^T \mathbf{P}_0 \mathbf{x} + \mathbf{q}_0^T \mathbf{x} + r_0 \\ & \text{subject to} && \frac{1}{2} \mathbf{x}^T \mathbf{P}_i \mathbf{x} + \mathbf{q}_i^T \mathbf{x} + r_i \leq 0 \quad i = 1, \dots, m \\ & && \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

- 半正定规划

$$\begin{aligned} & \underset{\mathbf{x}}{\text{minimize}} && \mathbf{c}^T \mathbf{x} \\ & \text{subject to} && x_1 \mathbf{F}_1 + x_2 \mathbf{F}_2 + \dots + x_n \mathbf{F}_n \preceq \mathbf{G} \\ & && \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

例:

3. 给定优化问题

$$\min_{x_1, x_2} \max\{x_1, x_2\}$$

$$\text{s. t.} \quad x_1, x_2 \geq 0$$

$$x_1 + 2x_2 \geq 1$$

$$2x_1 + x_2 \geq 1$$

(10 分)

- 1) 将上述优化问题表示为线性规划的标准形式. (5 分)
- 2) 线性规划可以通过调用 MATLAB 函数 `x=linprog(c,A,b)` 进行求解

(对应的标准形式为: $\min_{\text{s.t. } Ax \leq b} c^T x$), 写出具体调用表达式 (每个参

数的具体设置)。(5 分)

例:

(1) 将如下优化问题转化为线性规划 (LP) 问题。(6 分)

$$\min \|Ax - b\|_1 + \|x\|_\infty$$

(2) 设有 3 个点 x_1, x_2, x_3 , 寻找点 x 到 3 个点的最大欧式距离最小化, 将该问题表述为优化问题形式, 并转化为 QCQP 问题。(6 分)

最优性条件

最优性条件

对偶问题

KKT条件

■ 原问题

$$\begin{array}{ll} \underset{\mathbf{x}}{\text{minimize}} & f_0(\mathbf{x}) \\ \text{subject to} & f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & h_i(\mathbf{x}) = 0 \quad i = 1, \dots, p \end{array}$$

对偶问题

$$\begin{array}{ll} \underset{\lambda, \mathbf{v}}{\text{maximize}} & g(\lambda, \mathbf{v}) \\ \text{subject to} & \lambda \geq \mathbf{0} \end{array}$$

- **强对偶**: 对偶问题和原问题最优值相同
- **Slater约束规范**(Slater's Condition):

对凸优化问题, 只要有一个严格可行点, 强对偶即成立

最优性条件

■ KKT条件

1. 原问题可行 (primal feasibility):

$$f_i(\mathbf{x}^*) \leq 0, \quad i = 1, \dots, m, \quad h_i(\mathbf{x}^*) = 0, \quad i = 1, \dots, p$$

2. 对偶问题可行 (dual feasibility): $\lambda^* \geq 0$

3. 互补松弛条件 (complementary slackness): $\lambda_i^* f_i(\mathbf{x}^*) = 0$ for $\forall i$

4. 拉格朗日对 x 求导为零: ($\mathbf{x}^*$ minimizes $L(\mathbf{x}, \lambda^*, \nu^*)$)

$$\nabla f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i \nabla f_i(\mathbf{x}^*) + \sum_{i=1}^p \nu_i \nabla h_i(\mathbf{x}^*) = 0$$

例:

7. 对偶问题 (12 分)

优化问题

$$\min - \sum_{i=1}^m \ln(b_i - a_i^T x)$$

其中, x, a_i, b_i 是 $N \times 1$ 维列向量。

(1) 引入变量 $y_i = b_i - a_i^T x$, 将上述问题表示为等式约束问题。(6 分)

(2) 写出问题 (1) 的对偶问题。(6 分)

例：

5. 优化问题（12 分）

$$\begin{aligned} \min x_1 \ln x_1 + x_2 \ln x_2 \quad & \text{dom} = \{x_1, x_2 | x_1, x_2 > 0\} \\ \text{s.t. } x_1 + x_2 = 1 \end{aligned}$$

- （1）写出该问题的拉格朗日函数以及 KKT 条件。（6 分）
- （2）利用 KKT 条件，求解该优化问题。（6 分）

最优化算法

无约束优化
问题算法

0.618法

梯度下降法

牛顿法

等式约束优
化问题算法

消除等式约束

不等式约束
优化问题算
法

内点法

外点法

0.618法


$$b_k - \lambda_k = \mu_k - a_k$$

$$b_{k+1} - a_{k+1} = r(b_k - a_k)$$

$$\lambda_k = a_k + 0.382(b_k - a_k),$$

$$\mu_k = a_k + 0.618(b_k - a_k),$$

每次迭代只需要再选
选择一个试探点！
节省计算量



例:

2. 用 0.618 法求解下列问题最优解所处区间:

$$\min f(x) = e^{-2x} + x^3$$

要求最终区间长度 $L < 0.4$, 取初始区间 $[0, 1]$. (10 分)

x	0.146	0.236	0.382	0.618	0.764	0.854	1
$f(x)$	0.7494	0.6368	0.5215	0.5266	0.6629	0.8041	1.1353

梯度下降法

- 搜索方向如何选择？
- 梯度方向：函数值上升方向
- 梯度下降方向：
- 算法流程：
 - 给定初始点
 - 计算负梯度方向 $\Delta x = -\nabla f(x)$
 - 一维搜索步长 t
 - 更新 $x^{(k+1)} = x^{(k)} + t\Delta x$
- 终止准则： $\|\nabla f(\mathbf{x})\|_2 \leq \epsilon$

牛顿法

- 将一维搜索中的牛顿法推广
- 利用二阶近似

$$\begin{aligned} f(x) &\approx \phi(x) \\ &= f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) \\ &\quad + \frac{1}{2} (x - x^{(k)})^T \nabla^2 f(x^{(k)}) (x - x^{(k)}) \end{aligned}$$

- 求平稳点 $\nabla \phi(x) = 0$
- 牛顿法的迭代公式

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

例:

(1) 利用牛顿法求解

$$\min e^{-x} + x^2$$

初始点 $x^{(0)} = 0$ ，计算一次迭代结果。(6 分)

内点法

- 例:

$$\begin{aligned} \min \quad & \frac{1}{12}(x_1 + 1)^3 + x_2 \\ \text{s.t.} \quad & x_1 - 1 \geq 0 \\ & x_2 \geq 0 \end{aligned}$$

- 利用障碍函数转换为无约束问题

$$\min \quad \frac{1}{12}(x_1 + 1)^3 + x_2 - \frac{1}{t}(\log(x_1 - 1) + \log(x_2))$$

- 一阶导数为0

$$\begin{aligned} \frac{1}{4}(x_1 + 1)^2 - \frac{1}{t(x_1 - 1)} = 0 & \quad \longrightarrow \quad (x_1 + 1)^2(x_1 - 1) = \frac{4}{t} \quad t \rightarrow \infty \quad \longrightarrow \quad \begin{aligned} x_1 &= 1 \\ x_2 &= 0 \end{aligned} \\ 1 - \frac{1}{tx_2} = 0 & \quad \longrightarrow \quad x_2 = \frac{1}{t} \end{aligned}$$

有约束问题-外点法（罚函数）

- 罚函数

$$F(x, \sigma) = f_0(x) + \sigma \sum_i \left[\max\{0, f_i(x)\} \right]^2$$

- σ 为罚因子, σ 越大, 越逼近原问题的解
- 例:

$$\begin{array}{ll} \min & x \\ \text{s.t.} & x - 2 \geq 0 \end{array}$$

外点法

- 罚函数

$$F(x, \sigma) = x + \sigma P(x)$$

$$P(x) = [\max\{0, 2 - x\}]^2$$
$$= \begin{cases} 0 & x \geq 2 \\ (x - 2)^2 & x < 2 \end{cases}$$

- 求解无约束优化问题 $\min x + \sigma P(x)$

- 梯度为0

$$\bar{x}_\sigma = 2 - \frac{1}{2\sigma}$$

$$\sigma \rightarrow \infty, \quad \bar{x}_\sigma \rightarrow 2$$